

학술 포트폴리오 및 공개 저장소용 저널 형식 원고이며, SCI/KCI 학술지의 심사·게재를 받은 논문이 아님.

흐름에서 일부 가설이 기각되거나 부분적으로만 지지되더라도 그 과정을 숨기지 않고 연구결과로 포함하는 것을 원칙으로 하였다.

1.1 연구질문

RQ1. 어떤 공정변수가 고장과 관련되며, I-MR 관리도를 통해 선택적인 비정상 공정상태를 탐지할 수 있는가?

RQ2. 원시 센서변수, 물리 기반 파생변수, SPC 경보를 단계적으로 추가할 때 고장예측 성능은 어떻게 변하며 비선형 모델은 선형모델보다 우수한가?

RQ3. 확정된 고장위험 점수를 이용하여 실행가능 운전점과 제한된 운전시간 배분 문제를 어떻게 구성할 수 있는가?

1.2 연구가설과 사전 기대

가설	사전 기대	검토 지표
H1	토크·파워·속도의 SPC 정보군은 전체 평균보다 높은 고장위험을 보일 것이다.	위험비와 검출률
H2	온도계열은 관측순서상 기준선 이동이 존재할 경우 고정관리도 경보가 과다해질 것이다.	정보율·위험비·순서그래프
H3	기계적 파워와 온도차 파생변수는 원시변수만 사용한 모델보다 고장순위화 성능을 개선할 것이다.	A→B 성능
H4	기계적 SPC 경보를 추가한 Model C가 Model B보다 추가적 정보를 제공할 것이다.	B→C 성능 및 중요도
H5	고장규칙이 임계값·상호작용 구조라면 RF/GB가 Logistic 보다 우수할 것이다.	PR-AUC, Recall, FP/FN
H6	최종모델은 제약조건 아래 위험이 낮은 후보운전점을 제공할 수 있으나 인과적 최적점은 아닐 것이다.	격자탐색·LP·한계 명시

2. 데이터 및 연구설계

2.1 AI4I 2020 데이터 특성

AI4I 2020은 10,000 개의 공정 관측치와 제품 Type(L/M/H), 공기온도, 공정온도, 회전속도, 토크, 공구마모의 6 개 주요 입력변수, 전체 고장여부(Machine failure), 5 개 세부 고장모드(TWF, HDF, PWF, OSF, RNF)를 포함하는 합성 데이터이다 [1,2]. 실제 현장자료를 공개하기 어려운 예지보전 분야에서 방법론 검증에 위해 설계된 데이터라는 장점이 있지만, 합성 규칙이 비교적 명확하므로 실제 공장의 외란·센서열화·설비간 이질성을 충분히 반영하지 못한다는 한계도 동시에 가진다.

고장모드	공개된 합성 생성규칙	주요 변수
TWF	약 200-240 min 의 고마모 구간에서 교체/고장이 확률적으로 발생	공구마모
HDF	온도차 < 8.6 K 그리고 회전속도 < 1380 rpm	온도차, RPM
PWF	기계적 파워 < 3.5 kW 또는 > 9 kW	토크, RPM, 파워
OSF	공구마모×토크가 Type 별 임계값을 초과	마모, 토크, Type
RNF	공정조건과 독립된 무작위 고장	센서만으로 예측 곤란

이 공개 규칙들은 예측 입력으로 사용하지 않았으며, 최종모델을 확정한 이후 모델이 학습한 분할조건을 사후 해석하는 기준으로만 활용하였다. 따라서 본 연구의 예측문제에서 TWF/HDF/PWF/OSF/RNF는 정답에 가까운 누수변수로 간주하여 입력에서 제외하였다.

2.2 데이터 품질검토와 라벨 불일치

검토항목	관측결과
전체 관측치	10,000
결측치	0
완전중복	0
Machine failure=1	339 (3.39%)
세부고장모드가 1 개 이상인 행	348
고장모드=1 이나 Machine failure=0	18 (모두 RNF 관련)
Machine failure=1 이나 고장모드 없음	9
총 불일치 행	27

27 개 불일치 행을 임의로 삭제하거나 고치지 않았다. 전체 target 은 원본 Machine failure 를 유지하고, 고장모드 변수는 ML 학습에서 제외한 뒤 Test 이후 사후진단에만 사용하였다. 이 결정은 결과를 인위적으로 정리하는 대신 원본 데이터의 불확실성을 연구기록에 남기기 위한 것이다.

2.3 순차분할과 파생변수

구간	관측순서	n	고장	고장률
Train	1-7,000	7,000	278	3.971%
Validation	7,001-8,500	1,500	32	2.133%
Test	8,501-10,000	1,500	29	1.933%

실제 timestamp 와 설비 ID 가 없기 때문에 UDI 순서를 pseudo-time 으로 보았다. 무작위 분할 대신 연속 70/15/15 분할을 사용하여 미래구간을 학습에 섞지 않았지만, 이는 동일설비를 시간에 따라 추적한 진짜 시계열 검증은 아니다.

$$\text{온도차 } [K] = \text{공정온도 } [K] - \text{공기온도 } [K]$$

$$\text{기계적 파워 } [kW] = \text{토크 } [Nm] \times 2\pi \times \text{회전속도 } [rpm] / (60 \times 1000)$$

EDA 에서 고장군은 정상군보다 평균 토크 (50.17 vs 39.63 Nm), 공구마모 (143.78 vs 106.69 min), 기계적 파워 (7.283 vs 6.245 kW) 가 높았고 평균 회전속도는 낮았다 (1496.5 vs 1540.3 rpm). 토크와 파워는 강한 상관을 가지므로 이후 Logistic 계수나 변수중요도를 인과효과로 해석하지 않았다.

3. 통계적 공정관리: 사용이유, 기대, 결과

3.1 I-MR 관리도를 사용한 이유


각 행이 사전에 정의된 부분군의 평균이 아니라 개별 공정관측치이므로 I-MR 관리도를 선택하였다 [3,4]. 관리도는 고장을 직접 판별하기 위한 분류기가 아니라 'Train 기준에서 통계적으로 이례적인 관측'을 표시하는 장치로 정의하였다. 동시에 경보 여부를 0/1 파생변수로 만들어 ML 에 넣었을 때 추가적인 정보가 생기는지를 검증하고자 하였다.

$$MR_i = |x_i - x_{i-1}|, \quad \hat{\sigma} = MR\bar{d}_2 / d_2 \quad (d_2=1.128)$$


$$I \text{ 관리도: } UCL = \bar{x} + 3\hat{\sigma}, \quad CL = \bar{x}, \quad LCL = \bar{x} - 3\hat{\sigma}$$

$$MR \text{ 관리도: } UCL = D_4 MR\bar{d}_2, \quad CL = MR\bar{d}_2, \quad LCL = D_3 MR\bar{d}_2 \quad (D_4=3.267, D_3=0)$$

토크의 Train 7,000 개 기준 중심선은 39.93 Nm, UCL 69.79 Nm, LCL 10.06 Nm 이었다. 그림에는 가독성을 위해 첫 1,000 개만 제시하였으나 관리한계는 7,000 개 전체로 추정하였다.



(a) 토크 I 관리도



(b) 토크 MR 관리도

그림 2. 토크 I-MR 관리도. 관리한계 이탈은 특별원인 신호이며 고장과 동일한 개념이 아니다.

3.2 예상했던 결과: 기계계열 경보는 선택적이지만 강한 신호였다

Validation 변수	경보율 %	고장검출률 %	경보군 고장률 %	오경보율 %	위험비
공기온도	77.07	65.62	1.82	77.32	0.85
공정온도	91.13	96.88	2.27	91.01	1.06
회전속도	3.80	18.75	10.53	3.47	4.93
토크	1.33	12.50	20.00	1.09	9.38
기계적 파워	1.47	12.50	18.18	1.23	8.52
온도차	96.13	93.75	2.08	96.19	0.98

토크와 기계적 파워는 Validation 에서 각각 1.33%, 1.47%의 낮은 경보율을 보이면서 경보군 고장률이 20.0%, 18.18%로 높았다. 위험비는 9.38, 8.52였다. 이는 극단적인 기계부하가 고장과 강하게 연관된 선택적 신호라는 초기 예상과 일치한다. 그러나 실제 고장 32 건 중 각 변수는 4 건만 검출하여 독립적인 고장탐지기로는 부족하였다.

3.3 예상하지 못한 결과: 온도는 "특별원인"보다 기준선 이동에 가까웠다

온도계열은 예상과 달리 지나치게 많은 경보를 발생시켰다. 온도차는 Validation 에서 96.13%가 경보였지만 위험비는 0.98이었다. Train 평균 9.610 K가 Validation 에서 10.924 K로 이동했고 순서그래프에서도 구간 전체가 다른 수준으로 이동하는 모습이 나타났다. 따라서 고정 중심선의 I-MR 경보를 그대로 고장신호로 사용하면 공정의 새로운 기준상태까지 이상으로 판정하는 문제가 생겼다.




그림 3. 관측순서에 따른 온도차. Train/Validation 경계 이후 수준이 크게 이동하여 고정관리한계 적용의 한계를 보여준다.

3.4 왜 그림에도 Model C 를 만들었는가

SPC 자체가 전체 고장을 잘 잡지 못했음에도 토크·파워·RPM 정보를 Model C 에 넣은 이유는 '연속형 센서값 + 해석가능한 특별원인 여부'의 조합이 머신러닝에 추가정보를 제공하는지 확인하기 위해서였다. 즉 Model C 는 SQC 가 유용하다는 결론을 미리 정해놓고 만든 모델이 아니라 H4 를 검증하기 위한 실험모델이다. 이후 SPC 정보 중요도가 거의 0 으로 나온 결과는 이 가설의 부분적 기각으로 기록하였다.

4. 머신러닝 방법론과 알고리즘 세부과정

4.1 Model A/B/C: 알고리즘을 바꾸기 전에 입력정보의 가치를 검증

모델	입력변수	검증목적
A Base	Type, 공기/공정온도, RPM, 토크, 공구마모	원시 공정정보의 기준성능
B Engineered	A + 온도차 + 기계적 파워	물리 기반 파생변수의 추가가치
C SPC Enhanced	B + 토크/파워/RPM SPC 정보	통계적 특별원인 신호의 추가가치

A<B<C 의 중첩구조로 설계하였다. 우선 Logistic Regression 을 고정한 채 A/B/C 만 바꾸어 Feature Engineering 과 SQC 의 효과를 분리해서 보았다. 이후 알고리즘 비교에서는 동일한 Model C 입력을 사용하여 Logistic, Random Forest, Gradient Boosting 의 구조적 차이를 비교하였다.

4.2 Logistic Regression: 해석가능한 선형 기준모형

$$\text{logit}(p)=\beta_0+\sum\beta_jx_j, \quad p=1/(1+e^{-z})$$

Logistic Regression 은 각 변수의 선형결합을 고장 log-odds 로 연결하는 확률모형이다. 숫자형 변수는 StandardScaler 로 표준화하고 Type 은 One-Hot Encoding 하였다. 고장비율이 3.39%에 불과하므로 class_weight='balanced'를 적용하여 고장 클래스의 손실기여도를 높였다. 본 모델은 최종성능보다 '선형관계만으로 어디까지 설명되는가'와 파생변수 효과를 해석하기 위한 기준선으로 사용하였다.

Logistic 입력	Precision	Recall	F1	PR-AUC	FP	FN	TP
A Base	0.2769	0.5625	0.3711	0.3595	47	14	18
B Engineered	0.2386	0.6562	0.3500	0.4480	67	11	21
C SPC Enhanced	0.2500	0.6875	0.3667	0.4458	66	10	22

Model B 에서 Recall 은 0.5625→0.6562, PR-AUC 는 0.3595→0.4480 으로 개선되어 기계적 파워·온도차 파생이 유의미하다는 H3 가 지지되었다. Model C 는 Recall 을 0.6875 로 높였지만 PR-AUC 는 0.4458 로 소폭 하락하였다. 즉 SPC 정보는 임계값 0.5 에서 고장을 조금 더 많이 잡았지만 전체 순위화 능력을 개선하지는 못했다.

Logistic C 의 표준화 계수는 토크 +7.454, 기계적 파워 -4.420, RPM +2.301, 공구마모 +0.894 등으로 나타났다. 그러나 파워가 토크와 RPM 으로 만든 파생변수이기 때문에 다중공선성과 상호의존성이 존재한다. 따라서 계수 부호를 '토크는 고장원인이고 파워는 고장을 감소시킨다'처럼 인과적으로 읽지 않았다. 실제 ablation 에서 파워를 제거하면 PR-AUC 가 0.4458→0.3079 로 하락했고, 토크·RPM 을 제거하고 파워만 남기면 0.1785 까지 하락하였다. 결론은 파워가 원변수를 대체하는 것이 아니라 상호작용정보를 보완한다는 것이다.

4.3 Random Forest: 여러 트리를 병렬로 결합하는 Bagging 앙상블

Random Forest 는 bootstrap 표본으로 다수의 Decision Tree 를 만들고 각 분기에서 일부 변수만 후보로 사용한 뒤, 트리들의 투표/확률을 평균하는 모델이다 [5]. 단일 Tree 가 특정 표본에 과적합되는 문제를 여러 랜덤트리의 평균으로 완화하면서도 'RPM 이 낮고 온도차가 작다', '마모와 토크가 동시에 높다'와 같은 비선형 조건을 표현할 수 있다. 본 연구에서는 n_estimators=300, class_weight='balanced', random_state=42 를 사용하였다. 트리에서는 변수의 절대적도보다 분할순서가 중요하므로 숫자형 표준화는 사용하지 않았다.

$$\hat{p}_{RF}(x) = (1/B) \sum_{b=1}^B \hat{p}_b(x), \quad B=300$$

동일한 Model C 입력에서 Random Forest 는 Precision 0.7500, Recall 0.6562, F1 0.7000, PR-AUC 0.7455 를 기록했다. Logistic C 의 FP 66 건이 RF 에서는 7 건으로 크게 줄었다. 이는 본 데이터의 고장구조가 단순한 하나의 선형 경계보다 임계조건과 변수 상호작용에 가깝다는 H5 를 강하게 지지한다.

4.4 Gradient Boosting: 틀린 부분을 순차적으로 보정하는 앙상블

Gradient Boosting 은 여러 트리를 독립적으로 만든 RF 와 달리, 현재 앙상블이 남긴 오차방향을 다음 얇은 Tree 가 순차적으로 보정한다 [6]. 본 연구에서는 $n_estimators=200$, $learning_rate=0.05$, $max_depth=3$, $random_state=42$ 를 사용하고 고장 희소성을 고려한 balanced sample weight 를 학습에 전달하였다. 얇은 트리를 작은 학습률로 계속 더하는 구조는 희소하지만 반복적으로 남는 hard failure case 를 보정하는 데 적합할 것으로 예상하였다.

$$F_m(x) = F_{m-1}(x) + \eta h_m(x), \quad \eta = 0.05, \quad m = 1, \dots, 200$$

Why Three Models? Increasing Representational Complexity




그림 4. 세 알고리즘을 선택한 논리. 선형모형→Bagging 비선형모형→순차 보정형 비선형모형으로 표현력을 단계적으로 높였다.

4.5 최종 Gradient Boosting 내부 Tree 가 보여준 실제 분할

최종 직렬화 모델의 첫 번째 depth-3 약한 학습기를 직접 확인하였다. Root 는 RPM 1386.5 에서 분기했고, 저속 branch 에서 온도차 8.65 K, 다시 RPM 1380 으로 분기하였다. 다른 branch 에서는 기계적 파워 3.496 kW 와 공구마모 201.5 min 이 주요 경계였다. 이는 AI4I 문서의 HDF 조건(온도차 8.6 K, RPM 1380), 저파워 PWF 조건(3.5 kW), 고마모 구간(약 200 min 이후)과 매우 근접한다. 따라서 GB 가 임의의 잡음을 맞춘 것이 아니라 합성데이터의 비선형 구조를 빠르게 포착했다는 해석이 가능하다. 단, 그림의 node value 는 고장확률이 아니라 boost residual correction 이고, 실제 최종예측은 200 개 트리의 합으로 결정된다.

First Weak Learner in the Final Gradient Boosting Ensemble (Iteration 1)
Split conditions are from the serialized final model




그림 5. 최종 Gradient Boosting 모델의 첫 번째 약한 학습기. 분할값은 저장된 실제 모델에서 추출하였으며 node value 는 잔차 보정값이다.

메커니즘	공개 합성규칙	첫 GB Tree 에서 관찰된 분할
HDF	$\Delta T (8.6 \text{ K} \ \& \ \text{RPM} < 1380)$	$\text{RPM} \leq 1386.5 \rightarrow \Delta T \leq 8.65 \rightarrow \text{RPM} \leq 1380$
PWF 저파워	$\text{Power} < 3.5 \text{ kW}$	$\text{Power} \leq 3.496 \text{ kW}$
고마모	TWF 200~240 min 구간 / OSF 는 마모×토크	$\text{Tool wear} \leq 201.5 \text{ min}$

메커니즘	공개 합성규칙	첫 GB Tree 에서 관찰된 분할
고부하	PWF>9 kW / OSF 마모×토크	첫 Tree 는 저 RPM branch 에서 Power 7.46 kW 를 사용; 후속 Tree 들이 보정

4.6 성능지표와 Threshold 를 왜 따로 선택했는가

$$Precision=TP/(TP+FP), Recall=TP/(TP+FN), F1=2PR/(P+R)$$

고장이 3.39%인 불균형 데이터에서는 Accuracy 가 모델의 실질적 유용성을 과장할 수 있으므로 Precision, Recall, F1, ROC-AUC, PR-AUC 와 FP/FN/TP/TN 을 함께 보았다 [8-10]. 특히 PR-AUC 는 희소한 고장클래스의 순위화 성능을 보는데 더 적합하다고 판단하였다. 또한 predict_proba 가 만든 연속점수를 0/1 로 바꾸는 threshold 는 운영정책의 일부로 간주하였다.

Validation 에서 RF 와 GB threshold 를 0.10~0.90 범위로 비교한 결과, 본 연구의 목적이 '고장 누락 최소화'에 더 가까웠기 때문에 Recall≥0.75 를 유지하면서 Precision 이 높은 지점을 우선 검토하였다. GB threshold 0.65 에서 Precision 0.5435, Recall 0.7812, F1 0.6410 을 얻었고 이 값을 Test 를 보기 전에 고정하였다.




그림 6. Threshold 변화에 따른 Precision-Recall trade-off. 최종 0.65 는 Validation 에서 결정하였다.

5. 머신러닝 결과와 해석

모델	Precision	Recall	F1	PR-AUC	FP	FN	TP
Logistic C	0.2500	0.6875	0.3667	0.4458	66	10	22
Random Forest	0.7500	0.6562	0.7000	0.7455	7	11	21
Gradient Boosting	0.3968	0.7812	0.5263	0.7718	38	7	25





그림 7. 동일한 Model C 입력에서 알고리즘 비교, RF는 정밀도/F1, GB는 Recall/PR-AUC가 우세하였다.


RF는 정상인데 고장으로 올리는 FP를 최소화하는 관점에서 매우 우수했다. 반면 GB는 32개 Validation 고장 중 25개를 탐지하여 Recall과 PR-AUC가 가장 높았다. 예지보전에서는 FN이 생산중단·설비손상으로 이어질 수 있다는 운영적 신호를 반영하여 GB를 최종모델로 선택하였다. 이는 보편적인 최적모델 선언이 아니라 본 연구의 목적함수에 따른 선택이다.

5.1 Test 성능과 일반화 확인

구간	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC	FP	FN	TP	TN
Validation @0.65	0.9813	0.5435	0.7812	0.6410	0.9857	0.7718	21	7	25	1447
Test	0.9833	0.5526	0.7241	0.6269	0.9615	0.7463	17	8	21	1454



(a) Test 혼동행렬



(b) PR-AUC permutation importance

그림 8. 최종 Test 결과와 변수 중요도. Test 29 개 고장 중 21 개를 탐지하고 8 개를 놓쳤다.

Validation 에서 Test 로 Recall 은 0.7812→0.7241, PR-AUC 는 0.7718→0.7463 으로 소폭 감소했지만 큰 붕괴 없이 유지되었다. Test 결과를 본 뒤 threshold 나 모델을 다시 바꾸지 않았기 때문에 이 성능을 최종 일반화 결과로 기록하였다.

5.2 SQC 가 ML 에서 생각보다 큰 역할을 하지 못한 이유

GB built-in importance 에서는 RPM 0.3467, 기계적 파워 0.2697, 공구마모 0.2046, 온도차 0.0905, 토크 0.0758 이 상위였다. PR-AUC permutation importance 에서는 기계적 파워 0.5909, 공구마모 0.3325, RPM 0.1001, 토크 0.0859 가 핵심이었고 Torque/Power SPC alarm 은 0 에 가까웠다. 즉 '관리한계를 넘었는가'라는 이진정보보다 '실제 값이 얼마이며 다른 변수와 어떤 조합을 이루는가'가 GB 에 더 유용했다.

이는 SQC 가 실패했다는 뜻이 아니다. 토크 SPC 정보는 위험비 9.38 이라는 해석가능한 고위험 신호였지만 전체 Failure 를 넓게 순위화하기에는 희소했다. ML 은 정답 라벨을 직접 보면서 더 유리한 임계값과 상호작용을 학습할 수 있다. 따라서 최종 역할분담은 'SQC=공정감시 및 설명가능한 escalation', 'ML=다변량 고장위험 순위화'로 정리하였다.

5.3 고장모드 사후진단

모드	실제	탐지	탐지율	평균점수	Power	Wear	RPM	Torque
TWF	7	1	14.3%	0.325	5.801	210.4	1686	35.4
PWF	7	7	100%	0.978	9.548	115.1	1365	66.9
OSF	17	16	94.1%	0.905	8.236	207.6	1362	57.8

PWF 와 OSF 는 매우 잘 잡았지만 TWF 는 7 건 중 1 건만 탐지하였다. PWF 는 정의 자체가 파워 임계값에 기반하고 OSF 는 마모×토크에 기반하므로 Model C 의 핵심 연속변수와 강하게 겹친다. 반면 TWF 는 200-240 분의 고마모 영역에서 교체 또는 고장이 확률적으로 결정되는 구조이므로 높은 공구마모 하나만으로 모든 TWF 를 분류하기 어렵다. 이 결과는 '모델이 고장을 잘 맞춘다'는 단일 숫자보다 어떤 failure mechanism 에 강하고 약한지를 보여준다.

6. 최적화 및 의사결정 전환



6.1 RPM-토크 운전점 최적화

GB 예측함수는 비선형이고 기계적 파워도 RPM×Torque 의 곱이므로 이 문제에 Simplex 를 억지로 적용하지 않았다. 의사결정변수는 RPM 과 Torque 로 두고, 온도·Type·공구마모는 기준시나리오에 고정하였다. Train 의 5~95 분위 범위에서 60×60=3,600 개의 후보를 만들고 최소 기계적 파워 제약을 만족하는 후보에 대해 최종 GB 점수를 계산하였다.

$$\min \hat{p}_{\text{failure}}(\text{RPM}, \text{Torque} \mid \text{고정 시나리오})$$

$$\text{s.t. } \text{Power} \geq \text{Train median}, \text{RPM}_{0.05} \leq \text{RPM} \leq \text{RPM}_{0.95}, \text{Torque}_{0.05} \leq \text{Torque} \leq \text{Torque}_{0.95}$$

1,999 개의 실행가능 후보 중 여러 점이 동일한 최저점수를 보였고 대표점으로 1768.339 rpm, 41.446 Nm, 7.675 kW, 예측 점수 1.3046%를 제시하였다. 이것은 연속공간의 유일한 물리적 최적점이 아니라 '현재 모델과 고정조건 아래에서 낮은 점수로 평가된 후보'이다.



(b) 공구마모 민감도

(a) RPM-토크 위험표면

그림 9. 최적화와 민감도분석. 색상/백분율은 보정되지 않은 모델점수이며 실제 고장확률로 직접 해석하지 않는다.

6.2 공구마모 민감도에서 얻은 추가 해석

처음 25/50/75 분위 마모값(약 53/109/163 min)만 비교했을 때 최적점과 위험이 거의 동일하여 공구마모 효과가 없어 보였다. 그러나 RPM·Torque를 최적점에 고정하고 마모를 연속적으로 변화시키자 약 200 min 이후 점수가 급격히 상승했다. 100 개 grid에서 5%, 10%, 20%를 처음 넘은 마모는 약 202.727 min 이었고 점수는 23.401%로 점프하였다. 이는 Tool wear가 선형적으로 조금씩 위험을 증가시키는 변수가 아니라 Tree의 임계분할과 다른 변수의 조합 속에서 작동함을 보여준다. 다만 이후 점수는 단조증가하지 않으므로 202.7분을 실제 교체기준으로 제안해서는 안 된다.

6.3 Simplex를 적용한 선형계획 확장

운전점 탐색과 별개로, ML 점수를 운영계획에 넘기는 방법을 보이기 위해 두 운전모드의 시간배분 LP를 구성하였다. A는 저위험 대표점, B는 고출력·고점수 운전점으로 두었다. 8시간 내에서 총 파워점수를 최대화하고 risk exposure budget을 제한하였다.

$$\max Z = P_A x_A + P_B x_B$$

$$s.t. x_A + x_B \leq 8, r_A x_A + r_B x_B \leq R_{max}, x_A, x_B \geq 0$$

LP는 A 4.8 h, B 3.2 h를 반환하였다. 여기서 중요한 결론은 '이 비율이 실제 최적 운전계획'이라는 것이 아니다. risk budget 자체를 60/40 혼합점수로 만든 시나리오이므로 결과가 그 가정을 재현하는 성격이 크다. 따라서 본 LP는 예측값을 Simplex 기반 자원배분으로 전달하는 구조를 검증한 예제이며, 후속연구에서는 실제 생산가치·정비시간·고장비용으로 제약과 목적함수를 추정해야 한다.




그림 10. 2 변수 선형계획의 실행가능영역과 꼭짓점 해. 비선형 운전점 탐색과 달리 이 단계에서는 목적함수와 제약이 선형이므로 Simplex 원리를 적용할 수 있다.

7. 논의: 가설검증과 연구 흐름에 대한 평가

가설	판정	핵심근거
H1	조건부 지지	기계 SPC는 위험을 놓쳤으나 coverage가 낮았다.
H2	지지	온도는 특별원인보다 baseline shift로 해석하는 것이 타당했다.
H3	지지	Model B에서 Recall/PR-AUC가 개선되었다.
H4	부분지지·사실상 부정적	Model C Recall은 소폭 증가했으나 PR-AUC 및 중요도에서 SPC 이득이 거의 없었다.
H5	강하게 지지	RF/GB가 Logistic보다 크게 우수했고 실제 GB Tree가 합성 임계규칙과 유사한 분할을 학습했다.
H6	의사결정 원형 수준에서 지지	실행가능 후보와 LP는 만들었지만 인과·경제 최적정책은 아니다.

7.1 기대와 달랐던 결과의 의미

본 연구의 질을 높인 부분은 모든 방법이 예상대로 성공한 것이 아니라, 예상과 다른 결과를 다음 분석의 의사결정으로 연결했다는 점이다. SQC에서 온도경보가 사실상 대부분의 관측을 올렸을 때 이를 '온도가 중요하다'로 포장하지 않고 기준선 이동으로 해석하여 SPC 입력에서 제외하였다. 토크·파워 경보가 높은 위험비를 보였을 때도 coverage가 낮다는 점을 동시에 기록하였다. 이후 Model C에서 SPC 중요도가 거의 0으로 나타나자 SQC-ML 결합이 무조건 성능개선을 만든다는 가설을 수정하였다.

또한 Random Forest와 Gradient Boosting의 개선은 단순히 복잡한 모델이어서가 아니라 데이터 자체의 고장구조가 임계값과 곱형 상호작용을 포함하기 때문으로 해석하였다. 최종 GB의 첫 Tree가 HDF와 PWF 임계값을 거의 그대로 회복한 것은 이를 시각적으로 확인시켜준다. 반대로 이러한 '잘 맞음'은 AI4I가 합성규칙을 가진 데이터이기 때문에 실제설비보다 쉬운 문제일 수 있다는 외적타당성 한계도 동시에 드러낸다.

7.2 현재 흐름의 신뢰성

분석 절차의 내부 신뢰성을 위해 Train에서 파생변수와 관리한계를 추정하고 Validation에서 모델·threshold를 선택한 뒤 Test를 마지막에 열었다. Test 성능을 보고 다시 threshold를 바꾸지 않았다. 따라서 적어도 현재 데이터 안에서는 선택-평가 경계가 비교적 명확하다. 그러나 하나의 pseudo-sequential split 뿐이고 asset ID가 없으므로 여러 설비와 시간구간에서 재현될 것이라는 주장은 할 수 없다.

8. 연구의 한계 및 후속연구

- 합성데이터 한계: 실제 센서노이즈, 결측, 설비별 편차, 예방정비 이력, 부품교체, censored lifetime이 없다.
- 실제 시간정보 부재: UDI 순서를 시간처럼 사용했지만 shift, 날짜, 정지시간, 가열·냉각주기를 확인할 수 없다.
- 검증구조 한계: 단일 70/15/15 연속분할이므로 rolling-origin, blocked cross-validation, 외부데이터 검증이 필요하다.
- 확률보정 미수행: 1.3046%와 같은 값은 모델점수이며 실제 현장 고장확률이 아니다. Platt/isotonic calibration과 calibration curve가 필요하다.
- 모델탐색 범위: LR-RF-GB는 연구가설 검증을 위한 대표 모델군이며 모든 모델을 비교한 benchmark가 아니다. 이후 XGBoost/LightGBM, cost-sensitive learning, survival model, sequence model을 비교할 수 있다.
- SPC 가정: I-MR의 정상성·독립성을 변수별로 충분히 검증하지 못했다. 실제 timestamp가 확보되면 EWMA, CUSUM, change-point detection, Hotelling T^2 /MEWMA로 확장할 수 있다.
- 인과성 부재: 변수중요도와 Tree 분할은 예측관련성이다. RPM/토크를 실제로 조절하거나 공구를 교체했을 때 고장이 줄어드는지는 intervention 데이터로 검증해야 한다.
- 최적화 가정: 생산량, 정비비용, 고장손실, 인력시간이 없어 scenario-based 제약을 사용하였다. 실제 현장에서는 기대비용 최소화, stochastic/robust optimization, MILP로 확장해야 한다.

8.1 후속연구 로드맵

단계	확장방향
1 단계	실제 timestamp·asset ID·정비이력·고장비용을 포함한 장기설비 데이터 수집
2 단계	설비/운전모드별 정상 baseline 구축 및 CUSUM/EWMA/변화점 탐지 비교
3 단계	rolling validation, probability calibration, cost curve, subgroup robustness 평가
4 단계	SHAP/PDP 와 고장모드별 모델을 이용한 설명력 강화 및 causal/intervention 검증
5 단계	실제 정비이력·부품·생산가치를 포함한 MILP/robust optimization
6 단계	현장 shadow-mode 적용 후 엔지니어 검토와 prospective 성능평가

9. 결론

본 연구는 EDA→SQC→Feature Engineering→ML→사후진단→최적화라는 흐름을 통해 예지보전을 '정확도 높은 분류기'보다 넓은 의사결정 문제로 다루었다. SQC에서는 토크·파워가 선택적 고위험 신호였지만 전체 고장을 포괄하지 못했고, 온도는 기준선 이동 때문에 고정관리도 적용에 한계가 있었다. 물리 기반 파생변수는 Logistic 기준모형의 PR-AUC를 개선했으나 SPC 정보의 추가적 예측기여는 크지 않았다. 비선형 모델은 선형모델보다 현저히 우수했고, Gradient Boosting은 Validation에서 가장 높은 Recall·PR-AUC를 보여 고장미탐을 중시하는 최종모델로 선택되었다. 고정된 threshold 0.65로 Test 29건 중 21건을 검출했고, 첫 GB Tree는 AI4I의 합성 고장임계값에 가까운 분할을 학습하였다. 최적화는 낮은 모델점수의 실행가능 운전점을 제시하고 공구마모 고위험영역과 LP 자원배분 연결구조를 보여주었다. 중요한 결론은 모든 단계가 처음 기대대로 성공한 것이 아니라, 실패한 가설과 예상치 못한 결과가 다음 분석 선택을 바꾸었고 그 결정과 한계를 투명하게 남겼다는 점이다. 이는 학부 개인연구로서 결과 자체뿐 아니라 연구사고의 흐름과 검증절차를 보여주는 핵심 가치이다.

연구윤리 및 선언

연구상태. 본 원고는 가천대학교 산업공학과 신도윤의 독립 학부연구이며, SCI/KCI 학술지의 심사·게재를 받은 논문으로 표시하지 않는다.

저자기여. 연구질문과 가설 설정, 분석순서와 방법 선택, 결과검토와 해석, 최종내용의 책임은 저자에게 있다.

생성형 AI 활용. 일부 Python 코드 초안·디버깅·개념설명, 문장교정 및 문서 레이아웃 지원에 생성형 AI를 보조적으로 사용하였다. 수치결과, 표, 모델파일, 경험적 그림은 저장된 원데이터와 노트북 출력에 대조하여 검토하였다. 생성형 AI는 실증근거로 사용하지 않았으며 최종 분석선택과 해석의 책임은 저자에게 있다.

연구비 및 이해상충. 외부연구비 지원은 없으며 재정적·비재정적 이해상충이 없다.

데이터 및 코드. 원데이터는 UCI Machine Learning Repository의 AI4I 2020(CC BY 4.0)이며, GitHub 포트폴리오에는 EDA·SQC·ML·최적화 노트북과 주요 그림·모델 산출물을 공개할 수 있도록 구성한다.

참고문헌

- [1] UCI Machine Learning Repository. AI4I 2020 Predictive Maintenance Dataset. 2020. DOI: 10.24432/C5HS5C.
- [2] Matzka S. Explainable Artificial Intelligence for Predictive Maintenance Applications. 2020 Third International Conference on Artificial Intelligence for Industries; 2020:69–74. DOI: 10.1109/AI4I49448.2020.00023.
- [3] Montgomery DC. Introduction to Statistical Quality Control. 8th ed. Wiley; 2019.
- [4] NIST/SEMATECH. e-Handbook of Statistical Methods: Individuals Control Charts. 2012.
- [5] Breiman L. Random Forests. Machine Learning. 2001;45:5–32. DOI: 10.1023/A:1010933404324.
- [6] Friedman JH. Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics. 2001;29(5):1189–1232. DOI: 10.1214/aos/1013203451.
- [7] Pedregosa F, et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research. 2011;12:2825–2830.

- [8] Davis J, Goadrich M. The Relationship Between Precision–Recall and ROC Curves. ICML; 2006:233–240. DOI: 10.1145/1143844.1143874.
- [9] Fawcett T. An Introduction to ROC Analysis. Pattern Recognition Letters. 2006;27(8):861–874. DOI: 10.1016/j.patrec.2005.10.010.
- [10] Saito T, Rehmsmeier M. The Precision–Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE. 2015;10(3):e0118432. DOI: 10.1371/journal.pone.0118432.
- [11] Strobl C, Boulesteix A–L, Kneib T, Augustin T, Zeileis A. Conditional Variable Importance for Random Forests. BMC Bioinformatics. 2008;9:307. DOI: 10.1186/1471–2105–9–307.
- [12] Virtanen P, et al. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. Nature Methods. 2020;17:261–272. DOI: 10.1038/s41592–019–0686–2.

부록 A. 재현성 체크포인트

항목	고정값/규칙
데이터	AI4I 2020, 10,000 행
분할	관측순서 기준 연속 70/15/15
Target	Machine failure
최종입력	Type, 6 개 원시변수, 온도차, 기계적 파워, 토크/파워/RPM SPC 경보
Logistic	class_weight=balanced, max_iter=2000
RF	n_estimators=300, class_weight=balanced, random_state=42
GB	n_estimators=200, learning_rate=0.05, max_depth=3, balanced sample weight
최종 threshold	0.65, Test 이전 Validation 에서 고정
Test 혼동행렬	TN 1454, FP 17, FN 8, TP 21
격자탐색	RPM 5~95 분위 × Torque 5~95 분위, 60×60
대표 운전점	1768.339 rpm, 41.446 Nm, 7.675 kW, score 1.3046%
Software	Python, pandas, NumPy, scikit-learn, SciPy, Matplotlib, joblib